

한국어 형태소 정규화와 복잡도 기반의 라우팅을 이용한 품질 검증형 LLM API 비용 최적화 프록시

채준(*), 곽노윤(**)[†]

(*) 백석대학교 컴퓨터공학부, chaejoon23@bu.ac.kr

(**) 백석대학교 컴퓨터공학부, nykwak@bu.ac.kr

[†]지도교수(Supervisor): 곽노윤

1. 서론

자연어 프롬프트만으로 소프트웨어를 작성하는 이른바 바이브 코딩(vibe coding)의 확산과 함께 개인 개발자부터 기업까지 LLM API 사용량이 급격히 증가하고 있다. 그러나 LLM 기반의 기능은 한 번 개발하면 끝나는 것이 아니라, 최종 사용자가 기능을 호출할 때마다 토큰 단위로 과금되는 종량제 구조를 가진다[1]. 즉, 실질적인 비용은 ‘도입’이 아니라 ‘운영’ 단계에서 발생하며, 사용자가 늘수록 비용도 비례하여 누적된다. 통제 장치가 없는 경우 단기간에 수천에서 수만 달러에 이르는 비용 급증(cost spike)이 보고되고 있고, LLM 운영 비용의 가시화와 최적화는 실무적으로 중요한 과제가 되었다[1].

비용 절감을 위한 기법은 학계에서 활발히 연구되어 왔다. Chen 등[2]은 질의를 저비용 모델에서 고비용 모델로 순차 위임하는 LLM 캐스케이드(FrugalGPT)를 제안해 GPT-4 대비 최대 98%의 비용 절감을 보고하였다. Ong 등[3]은 선호 데이터로 학습한 라우터(RouteLLM)로 강·약 모델을 동적 선택하여 품질 저하 없이 비용을 절반 이하로 줄였다. 프롬프트 압축 분야에서는 Jiang 등[4]의 LLMingua가 의미를 유지한 채 프롬프트를 최대 20배까지 압축하였다. 또한 동일 입력을 재사용하는 프롬프트 캐싱은 주요 상용 API에서 입력 비용을 크게 절감하는 기능으로 제공되고 있다.

그러나 기존의 도구와 연구에서는 두 가지 공백이 존재한다. 첫째, 품질 검증의 부재이다. 상용 게이트웨이(OpenRouter, Portkey, Helicone, LiteLLM 등)는 비용 절감과 트래픽 라우팅을 제공하지만, 비용을 줄인 뒤 응답 품질이 유지되었는지는 사용자가 별도로 확인해야 한다. 둘째, 한국어 특수성의 미반영이다. Yang

등[5]과 Petrov 등[6]은 토큰나이저가 비영어권 언어를 비효율적으로 표현해, 한국어가 영어 대비 동일 의미를 더 많은 토큰으로 인코딩함을 보였다. 이러한 토큰 불이익은 한국 기관이나 기업의 LLM 운영 비용을 직접적으로 가중시키지만, 한국어를 겨냥한 비용 최적화 기법은 상대적으로 미비한 수준이다.

본 논문은 이 두 공백을 동시에 해소하는 투명 프록시 프레임워크 일명 ‘minT(Multi Intelligent Native Token)’를 제안함에 그 목적이 있다. minT는 애플리케이션의 LLM 엔드포인트 주소(Base URL) 한 줄만 변경하면 기존 코드 수정 없이 적용된다. 내부적으로 (i)프롬프트 캐싱, (ii)한국어 형태소 정규화, (iii)복잡도 기반의 캐스케이드 라우팅의 3가지 최적화 엔진과 (iv)Shadow Mode 기반의 품질 검증을 결합한다. 특히 본 논문은 한국어 형태소 정규화를 단순한 토큰 절감 수단으로 보지 않고, 의미가 동일한 표면형 변이를 하나의 표준형으로 수렴시키는 캐시 키 정규화 함수로 재해석한다. 이를 통해 정규화 모듈과 캐싱 모듈 사이에 시너지를 형성하여, 한국어 질의의 캐시 적중률을 비정규화 대비 크게 향상시킨다.

본 논문의 2장에서는 관련 연구를 정리하고, 3장에서는 제안된 minT 프레임워크의 전체 구조와 세 엔진 및 품질 검증 기법을 설명한다. 4장에서는 실험 결과와 고찰을 제시하며, 5장에서 결론을 맺는다.

2. 관련 연구

- **LLM 비용 최적화:** Chen 등[2]은 비용 절감 전략을 프롬프트 적응, LLM 근사(캐싱·튜닝), LLM 캐스케이드의 세 범주로 정리하고, 약한 모델의 응답을

채점하여 신뢰도가 낮을 때만 강한 모델로 위임하는 캐스캐이드를 구현하였다. Ong 등[3]은 질의-모델 적합도를 학습한 라우터로 강·약 모델 쌍 사이를 선택하였다. 본 논문의 라우팅 엔진은 같은 캐스캐이드 패러다임을 따르되, 학습 기반의 라우터에 앞서 영지연(zero-latency) 휴리스틱 계층을 두어 단순 질의를 즉시 분기시키는 점이 다르다.

- **프롬프트 압축:** Jiang 등[4]의 LLMingua는 소형 언어 모델의 perplexity를 이용해 중요도가 낮은 토큰을 제거하는 coarse-to-fine 압축을 제안하였다. 토큰 단위 압축은 과업에 따라 의미 손실이 발생할 수 있기에 본 논문에서는 이를 선택적(opt-in) 기능으로 분리하고 기본 경로에는 의미 손실이 없는 형태소 사전 기반의 보수적 정규화를 배치한다.
- **한국어 토큰화:** Yang 등[5]은 토큰나이저 어휘가 모델 학습 데이터와 독립적으로 구성되어 한국어-중국어 등을 과소 대표함을 분석하였고, Petrov 등[6]은 동일 의미 문장에 대해 언어 간 토큰 수가 4배 이상 차이 날 수 있음을 보였다. 본 논문에서는 이 비효율을 비용 측면의 결점으로 보고, 한국어 표면형 정규화(surface form normalization)를 통해 일부를 회수한다.
- **품질 평가:** Zheng 등[7]은 강한 LLM을 심판으로 사용하는 LLM-as-a-Judge가 사람들의 선호와 80% 이상 일치함을 보였다. 본 논문에서는 이를 최적화 전후 응답의 동등성 자동 비교에 활용한다.

3. 제안된 minT 프레임워크

3.1 전체 구조

제안된 프레임워크는 애플리케이션과 LLM 제공자 사이에 위치하는 투명 프록시(transparent proxy)로 동작한다. 그림 1은 제안된 minT 처리 파이프라인을 나타낸 것이다. 사용자는 LLM 클라이언트의 Base URL을 minT 엔드포인트로 변경하기만 하면 되며, 요청·응답 형식은 기존 API와 호환된다. 입력 질의 p 가 도착하면 그림 1과 같은 파이프라인을 거친다.




그림 1. 제안된 minT 처리 파이프라인

- User Prompt → 한국어 형태소 정규화 $N(\cdot)$ → 프롬프트 캐시 조회 → (미스 시) 복잡도 기반 캐스케이드 라우터 → 모델 호출 → 응답 반환 및 Shadow Mode 품질 측정

1. **정규화**: p 를 표준형 $\hat{p} = N(p)$ 로 변환(3.2절).
2. **캐시 조회**: 표준형 해시 $k = SHA256(\hat{p})$ 를 키로 조회(적중 시 저장 응답을 0에 가까운 지연으로 반환, 비용 미발생)
3. **라우팅**: 캐시 미스 시 복잡도 점수 $s(\hat{p})$ 를 추정하여 모델 계층에 배정(3.3절)
4. **품질 측정**: 표본 비율에 대해 기준(baseline) 응답을 병행 생성하고 최적화 응답과 비교(3.4절)

3.2 한국어 형태소 정규화와 캐시 정규화

한국어는 교착어로서 동일 의미의 질의가 조사·어미 변이에 의해 다수의 표면형으로 나타난다. 예컨대, “결제 버그를 고쳐줘”, “결제 버그 좀 고쳐주세요”, “결제 버그 고쳐 줄래?”는 의미상 같지만 문자열로는 다르다. 원문을 그대로 해시하는 정확 일치(exact-match) 캐시는 이들을 서로 다른 키로 취급하여 모두 캐시 미스를 발생시킨다. 이는 한국어 질의에서 캐시 적중률이 구조적으로 낮아지는 원인이다. 형태소 정규화 함수 $N(\cdot)$ 을 두 수준으로 정의한다.

- **보수적 정규화(default, lossless)**: 형태소 분석기로 조사·어미를 표준형으로 치환하고 불필요한 공백·중복 종결어미 정리. 예: {비용을, 비용이, 비용은} → 비용(사전 기반이라 의미 보존)
- **공격적 압축(opt-in, lossy 가능)**: LLMingua[4]류 토큰 압축을 선택 적용(의미 손실 가능성으로 기본 비활성화하며 Shadow Mode 검증 통과 시에만 사용)

정규화 함수는 두 역할을 동시에 수행한다. 첫째, 입력 토큰 수를 직접 감소시킨다(식 1).

$$p_{tok} = 1 - |N(p)| / |p| \quad (1)$$

둘째, 표면형 변이를 표준형으로 수렴시키는 캐시 키 정규화 역할을 한다. 의미가 같은 질의가 동일 표준형 $\hat{p}$ 로 매핑되면 같은 캐시 키를 공유하여 첫 호출 이후 모두 적중한다(식 2).

$$H = \#\{\text{캐시 적중}\} / \#\{\text{전체 질의}\} \quad (2)$$

본 논문의 핵심 주장은 $N(\cdot)$ 이 식 (1)의 토큰 절감뿐 아니라 식 (2)의 적중률 H 를 함께 끌어 올린다는 모듈 간 시너지이다. 기존의 게이트웨이는 한국어 인지형 정규화기를 갖지 않은 채 원문 정확 일치 캐싱만 수행하므로 이 시너지를 활용하지 못한다.

3.3 복잡도 기반의 캐스케이드 라우팅

라우터는 질의의 인지적 난이도를 추정하여 비용·성능이 상이한 모델 계층에 배정한다(표 1). 단순 질의는 저비용 모델에 배정하고 고난도 추론은 고비용 모델에 배정해 불필요한 고가 호출을 줄인다.

표 1. 복잡도 기반 라우팅 계층 구성

계층	분류기	모델	단가	복잡도
L1	휴리스틱	분기 결정	~0ms·free	—
L2	로컬 SLM	Local SLM	~free	경계
L3	저가 API	Flash/Haiku	매우 낮음	단순
L4	Catch-all	중간 모델	낮음	중간
—	직접 배정	Sonnet/Opus	높음	복잡

복잡도 점수 s 는 표준형 질의 $\hat{p}$ 로부터 추출한 특징 벡터 $f(\hat{p})$ 의 가중합에 시그모이드를 적용해 계산한다(식 3). (특징: 토큰 길이, 코드 블록 비율, 추론 키워드 빈도, 문장 구조 깊이 등)

$$s(\hat{p}) = \frac{1}{1 + e^{-(\sum_i w_i f_i(\hat{p}) + b)}} \quad (3)$$

임계값 $\tau_1 < \tau_2$ 로 모델 계층 $m(\hat{p})$ 을 결정한다 (식 4).

$$m(\hat{p}) = \begin{cases} m_{low}, & s < \tau_1 \\ m_{mid}, & \tau_1 \leq s < \tau_2 \\ m_{high}, & s \geq \tau_2 \end{cases} \quad (4)$$

라우팅 안전장치는 네 가지다. 1)도입 초기 2주 Shadow Mode 보정(calibration), 2)약한 모델의 불확실성 신호 시 강한 모델로 자동 재시도 (fallback), 3)품질 점수가 임계치 미만이면 자동 비활성화(rollback), 4)코드·법률·의료 등 고위험 도메인은 기본 OFF. 라우팅은 opt-in이며, 기본 경로에는 손실 없는 캐싱과 보수적 정규화만 동작한다.

3.4 Shadow Mode 기반의 품질 검증

표본 질의에 대해 기준 응답 y_{base} 와 최적화 응답 y_{minT} 를 병행 생성한 뒤 LLM-as-Judge[7]로 비교한다. 심판 함수 $J(y_{base} + y_{minT})$ 판정을 집계하여 품질 동등 이상 비율 Q를 정의한다(식 5).

$$Q = (\#\{\text{동등}\} + \#\{\text{minT 우위}\}) / \#\{\text{전체}\} \quad (5)$$

Shadow Mode는 ‘미적용 시 비용’도 동시에 측정하므로 비용 절감률 R를 객관 산정할 수 있다 (식 6). $C(\cdot)$ 는 (단가×입출력 토큰 수)의 호출 비용이다.

$$R = 1 - (\sum_p C_{minT}(p)) / (\sum_p C_{baseT}(p)) \quad (6)$$

4. 실험 결과 및 고찰

4.1 실험 설정

한국어·영어 혼합 개발 질의 데이터셋을 단순 (함수 설명·단순 질문·번역), 중간(버그 수정·리팩토링·API 구현), 복잡(아키텍처 설계·분산 시스템) 3가지 난이도로 구성하였다. 비교 기준은 모

든 질의를 단일 고비용 모델로 처리하는 baseline이며, 지표는 토큰 절감률(식 1), 캐시 적중률(식 2), 비용 절감률(식 6), 품질 동등 이상 비율(식 5)이다.

4.2 한국어 형태소 정규화의 이중 효과

표 2는 보수적 정규화의 효과다. 평균 약 22%의 입력 토큰을 절감하면서, 표면형 변이를 표준형으로 수렴시켜 캐시 적중률을 약 41%에서 67%로 향상시켰다. 3.2절의 토큰 절감-캐시 적중 시너지를 뒷받침한다.

표 2. 정규화의 토큰 절감 및 캐시 적중 효과

항목	미적용	적용
평균 입력 토큰	100	약 78
토큰 절감률 p_{tok}	—	약 22%
캐시 적중률 H	약 41%	약 67%

4.3 통합비용 절감 및 품질 검증

표 3은 모듈별·통합 비용 절감률이다. 통합 적용 시 평균 약 62%가 절감된다. 표 4의 LLM-as-Judge 결과는 동등 약 92%, minT 우위가 약 5%, 기준 우위가 약 3%로, 동등 이상 Q가 약 97%였다. 절반 이상 비용을 절감하면서 품질을 대부분 유지하였다.

표 3. 모듈별·통합 비용 절감률

구성	비용 절감률 R
캐싱 only	약 30%
+ 한국어 정규화	약 45%
+ 복잡도 라우팅(통합)	약 62%

표 4. LLM-as-Judge 품질 비교

판정	비율
동등	약 92%
minT 우위	약 5%
기준 우위	약 3%
동등 이상 Q	약 97%




그림 2. 주간 비용 대시보드: 절감액 · 품질 동등 비율 · 모듈 상태 · 캐시 적중률




그림 3. 주간 품질 리포트: 동등/우위/열위 분포

4.4 고찰

한국어 형태소 정규화가 토큰 절감과 캐시 적중률 향상을 동시에 발생시킴을 확인하였다. 이는 한국어 인지형 정규화기가 없는 기존 게이트웨이가 놓치는 부분으로, 한국어 환경의 차별적 이점이다. 제안된 방법의 한계는 다음과 같다. 첫째, 데이터셋이 개발 질의에 편중되어 일반 대화·문서 작업으로의 일반화 검증이 필요하다. 둘째, 복잡

도 가중치는 휴리스틱이며 학습 기반 라우터[3]와의 비교가 향후 과제로 남는다. 셋째, 공격적 압축의 의미 보존 한계는 과업별 추가 정량화가 필요하다.

5. 결론

본 논문은 LLM API 운영 비용을 절감하면서 품질 유지 여부를 정량 검증하는 투명 프록시 프레임워크 minT를 제안하였다. 프롬프트 캐싱, 한국어 형태소 정규화, 복잡도 기반 캐스케이드 라우팅의 세 엔진과 Shadow Mode 품질 검증을 결합하며 Base URL 한 줄 변경만으로 적용된다. 특히 한국어 형태소 정규화를 토큰 절감 수단이자 캐시 키 정규화 함수로 재해석하여 두 모듈의 시너지를 정식화한 점이 핵심 기여이다. 예비 실험에서 정규화는 평균 약 22% 토큰을 절감하며 캐시 적중률을 약 41%에서 67%로 높였고, 통합 적용 시 평균 약 62% 비용 절감과 품질 동등 이상 약 97%를 달성하였다. 향후 데이터셋 도메인 다양화, 학습 기반 라우터 비교, 한국 PII 차단 및 국내 보안 인증 연계, 일본어 등으로의 확장을 계획한다.

참고 문헌

- [1] CloudZero, “2025 State of AI Costs,” Technical Report, 2025.
- [2] L. Chen, M. Zaharia, and J. Zou, “FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Performance,” arXiv:2305.05176, 2023.
- [3] I. Ong et al., “RouteLLM: Learning to Route LLMs with Preference Data,” arXiv:2406.18665, 2024.
- [4] H. Jiang, Q. Wu, C.-Y. Lin, Y. Yang, and L. Qiu, “LLMLingua: Compressing Prompts for Accelerated Inference of Large Language Models,” EMNLP, pp. 13358–13376, 2023.
- [5] J. Yang, Z. Wang, Y. Lin, and Z. Zhao, “Problematic Tokens: Tokenizer Bias in Large Language Models,”

arXiv:2406.11214, 2024.

- [6] A. Petrov, E. La Malfa, P. H. S. Torr, and A. Bibi, "Language Model Tokenizers Introduce Unfairness Between Languages," NeurIPS, 2023. (arXiv:2305.15425)
- [7] L. Zheng et al., "Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena," NeurIPS, 2023. (arXiv:2306.05685)